

# BÀI THỰC HÀNH SỐ 1



# Content

1. Lab 01 – Tiền xử lý văn bản
2. Lab 02 – Phân loại thư rác
3. Lab 03 – Nhận dạng thực thể được đặt tên (NER)

# 1. Tiền xử lý văn bản

- Mục đích: chuẩn hóa dữ liệu văn bản, giảm nhiễu, hỗ trợ mô hình học máy hiểu được văn bản.
- Quy trình:
  - Khảo sát dữ liệu.
  - Các kỹ thuật tiền xử lý cơ bản
    - Loại bỏ các ký tự đặc biệt
    - Chuyển về chữ thường
    - Chuẩn hóa từ viết tắt ( I'm => i am)
    - Loại bỏ stopwords ( this, this, the...)
    - Chuẩn hóa về về từ gốc (excited => excite)

## 2. Phân loại thư rác

- Dataset:

| B     | C                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |    |
|-------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| label | text                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                       | la |
| ham   | Subject: enron methanol ; meter # : 988291<br>this is a follow up to the note i gave you on monday , 4 / 3 / 00 { prelimina<br>flow data provided by daren } .<br>please override pop ' s daily volume { presently zero } to reflect daily<br>activity you can obtain from gas control .<br>this change is needed asap for economics purposes .                                                                                                                                                                                                                                                                                                                                            |    |
| ham   | Subject: hpl nom for january 9 , 2001<br>( see attached file : hplnol 09 . xls )<br>- hplnol 09 . xls                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                      |    |
| ham   | Subject: neon retreat<br>ho ho ho , we ' re around to that most wonderful time of the year - - - neor<br>i know that this time of year is extremely hectic , and that it ' s tough to thi<br>on the calender that i handed out at the beginning of the fall semester , th<br>i think we all agree that it ' s important for us to get together and have sor<br>the first option would be to have a retreat similar to what we ' ve done the<br>the second option would be to stay here in houston , have dinner togethe<br>email me back with what would be your preference , and of course if you<br>have a great weekend , great golf , great fishing , great shopping , or wha<br>bobby |    |
| spam  | Subject: photoshop , windows , office , cheap . main trending<br>abasements darer prudently fortuitous undergone<br>lighthearted charm orinoco taster<br>railroad affluent pornographic cuvier<br>irvin parkhouse blameworthy chlorophyll<br>robed diagrammatic fogarty clears bayda<br>inconveniencing managing represented smartness hashish<br>academies shareholders unload badness<br>danielson pure caffen<br>spaniard chargeable levin                                                                                                                                                                                                                                              |    |

|      |      |
|------|------|
| Ham  | 3672 |
| Spam | 1499 |

## 2. Phân loại thư rác

- Chia tập dữ liệu thành tập train dataset và test dataset với tỉ lệ test/train = 0.2
- Cân bằng dữ liệu tập train:

|      |      |   |      |      |
|------|------|---|------|------|
| Ham  | 2930 | → | Ham  | 1206 |
| Spam | 1206 |   | Spam | 1206 |

- Chuẩn hóa văn bản thành vector: Bag-of-words / TF – IDF
- Classification model: SVM
- Metrics: Precision, Recall, F1-score, accuracy

## 3. Nhận dạng thực thể được đặt tên (NER)

### 3.1. Bài toán

- Bài toán trích xuất các thực thể có tên (người, địa điểm, tổ chức,...) từ văn bản.
- Ví dụ
  - Nguyễn Văn A  $\rightarrow$  PERSON
  - (Công ty) XYZ  $\rightarrow$  ORGANIZATION
  - (Tỉnh) M  $\rightarrow$  LOCATION

# 3. Nhận dạng thực thể được đặt tên (NER)

## 3.2. Dataset

- Dataset eriktk/conll2003
  - Train: 14041 mẫu
  - Validation: 3250 mẫu
  - Test: 3453 mẫu
  - Features: 'id', 'tokens', 'pos\_tags', 'chunk\_tags', 'ner\_tags'
- Tập nhãn: 'O', 'B-PER', 'I-PER', 'B-ORG', 'I-ORG', 'B-LOC', 'I-LOC', 'B-MISC', 'I-MISC'

```
{ 'id': '0',  
  'tokens': ['EU',  
             'rejects',  
             'German',  
             'call',  
             'to',  
             'boycott',  
             'British',  
             'lamb',  
             '.'],  
  'pos_tags': [22, 42, 16, 21, 35, 37, 16, 21, 7],  
  'chunk_tags': [11, 21, 11, 12, 21, 22, 11, 12, 0],  
  'ner_tags': [3, 0, 7, 0, 0, 0, 7, 0, 0]}
```

Example

## 3. Nhận dạng thực thể được đặt tên (NER)

### 3.2. Phương pháp

- Trích xuất đặc trưng
  - Viết hoa chữ cái đầu
  - 3 ký tự cuối (nhận diện hậu tố kiểu như -ing, -son, ...)
  - POS tag
- Huấn luyện mô hình
  - Model: CRF (Conditional Random Fields)
  - Sử dụng GridSearchCV xác định tham số tối ưu.

Example



