

BÀI THỰC HÀNH SỐ 2



Content

1. Lab 01 – Word embeddings với Word2vec và Glove
2. Lab 02 – Trích xuất tóm tắt văn bản

1. Word embeddings với Word2Vec và Glove

1.1 Word2Vec

- Được giới thiệu bởi Google vào năm 2013.
- Là một mô hình học từ nhúng (word embedding) bằng cách dự đoán ngữ cảnh ngắn (3, 4, 5... – grams) trong văn bản => **Dựa vào ngữ cảnh cục bộ**
- Các từ có ngữ nghĩa tương tự sẽ có các vector gần nhau trong không gian embedding.

1. Word embeddings với Word2Vec và Glove


1.1 Word2Vec

- 2 kiến trúc chính
 - **CBow**
 - Huấn luyện mô hình dự đoán 1 từ khi biết các từ xung quanh.
 - Đầu vào là các one-hot vector của các từ context.
 - Đầu ra là one-hot vector của từ target.
 - Word Embedding được lấy từ ma trận W sau khi huấn luyện

1. Word embeddings với Word2Vec và Glove

1.1 Word2Vec

- 2 kiến trúc chính
 - **CBow**



1. Word embeddings với Word2Vec và Glove


1.1 Word2Vec

- 2 kiến trúc chính
 - **Skip-gram**
 - Huấn luyện mô hình dự đoán các từ xung quanh khi biết một từ.
 - Đầu vào là one-hot vector của từ đã biết.
 - Đầu ra là one-hot vector của các từ xung quanh.
 - Word Embedding được lấy từ ma trận W_{in} sau khi huấn luyện

1. Word embeddings với Word2Vec và Glove

1.1 Word2Vec

- 2 kiến trúc chính
 - Skip-gram



1. Word embeddings với Word2Vec và Glove

1.2 Glove

- **Global** Vectors for Word Representation.
 - Là một mô hình phát triển dựa trên **Word2vec** kết hợp học từ nhúng dựa trên thống kê toàn cục về tần suất đồng xuất hiện của từ trong văn bản.
- => Dựa vào **thống kê toàn cục**

Example corpus:

- I like deep learning
- I like NLP
- I enjoy flying

counts	I	like	enjoy	deep	learning	NLP	flying	.
I	0	2	1	0	0	0	0	0
like	2	0	0	1	0	1	0	0
enjoy	1	0	0	0	0	0	1	0
deep	0	1	0	0	1	0	0	0
learning	0	0	0	1	0	0	0	1
NLP	0	1	0	0	0	0	0	1
flying	0	0	1	0	0	0	0	1
.	0	0	0	0	1	1	1	0

1. Word embeddings với Word2Vec và Glove

1.2 Độ đo tương đồng – Cosine similarity

- **Cosine Similarity** đo lường độ tương đồng giữa hai vector bằng cách tính cosin của góc giữa chúng.
- Công thức:

$$\text{cosine_similarity}(\vec{A}, \vec{B}) = \frac{\vec{A} \cdot \vec{B}}{||\vec{A}|| \cdot ||\vec{B}||}$$

- Càng gần nghĩa $\Rightarrow$ góc càng nhỏ $\Rightarrow$ cosine_similarity càng lớn

2. Trích xuất tóm tắt văn bản

2.1 Bài toán

- Tóm tắt một văn bản bằng cách chọn ra các câu quan trọng nhất từ văn bản gốc
- Bản chất là **sequence classification**, trong đó mỗi câu được đánh giá (có/không) để đưa vào bản tóm tắt.

2. Tóm tắt văn bản bằng trích xuất

2.2. Dataset

```
{'doc': "by thomas durante a newly - released surveillance video taken from inside an oklahoma prison shows a former crime boss and key federal witness lured to his death by fellow inmates\nsix inmates have been charged with murder in what looks like a pre-planned attack in which they worked together , and even celebrated afterwards\nmollman , a former motorcycle gang member and admitted drug trafficker , was found in a cell at the grady county on may 17 , 2012\nhe had pleaded guilty to various drug charges and was a key witness for the government in an ongoing drug investigation\nthe six inmates charged in mollman 's murder have been identified as sitlington , grant curry , matthew jackson , joseph hill , jerry gonzales and steven nidey\nsitlington , whom grady county assistant district attorney Leah Edwards calls one of the primary attackers , is the first inmate to appear before a judge\nhis next court date is next month\nshe told news 9 : ' although much of what went on is obscured by the shutting of doors we still have a clearer picture of how the incident occurred and who the major players were\n' coordinated kill : six inmates have been charged with murder in what looks like a pre-planned attack where they worked together , and even celebrated afterwards defense : at one point , mollman emerges from the cell , appearing to fight off his attackers death : after the inmates come out of the cell again , mollman staggers before collapsing the video begins with two inmates standing around a common area , appearing to watch tv\ntwo more convicts then enters the frame , with one of them checking out doors and looking around the room\nhe then jumps on a table , signaling another inmate inside a cell on the second level\nbrutality : the inmates can then be seen hoisting mollman 's body and dragging him into an adjacent cell as you were : with mollman lying motionless , some of the inmates continue watching tv as others scramble to cover up the crime not long after the gesture , mollman , bald and dressed in his full prison jumpsuit , enters the shot with two others\ndeath in jail : mollman , an alleged member of the rogue motorcycle club , was arrested last year - the culmination of a 12 - year investigation into the gang they lead mollman up the stairs and into one of the cells\nwhile little can be seen on the video , it 's clear that mollman and the other inmates are involved in some type of scuffle\nat one point , mollman emerges with his fists up , fighting back against his attackers in a desperate attempt\nwhen they come out again , mollman staggers and collapses on the ground\nthe inmates then drag his lifeless body into one of the cells\nwith his feet sticking out of the cell door , the inmates appear to cover up the murder , with one of them wiping blood off the floor with a towel\njail officers responded minutes later and found mollman dead in the cell with cuts on his body and apparently beaten to death\nwhile they examined mollman 's body , two of the inmates appear to fist bump right outside the cell\nmollman , an alleged member of the rogue motorcycle club , was arrested last year - the culmination of a 12 - year investigation into the gang\nhis family had said that he was also attacked a week before his death\ncleanup : as mollman 's body lies in a doorway , one inmate hands another a towel to wipe away blood celebration : after jail officers arrived to investigate mollman 's death minutes later , two of the inmates appear to fist bump right outside the cell watch video here", 'labels': '1\n0\n1\n1\n0\n0\n0\n0\n1\n0\n0\n1\n1\n1\n0\n0\n0\n0\n0\n1\n0\n0\n0\n1', 'summaries': 'mollman found dead in prison cell last year while he was awaiting sentencing in a drug investigation\nhe was a key witness for the feds in a plea deal\ninmates can be seen on video leading mollman to his death in what appears to be a pre-planned and coordinated effort'}
```

Example

Dataset	Kích thước
Train dataset	193983
Validation dataset	12147
Test dataset	10350

Kích thước

2. Tóm tắt văn bản bằng trích xuất

2.3. Các kiến trúc liên quan

- RNN:

A Simple RNN Language Model

output distribution

$$\hat{y}^{(t)} = \text{softmax}(U h^{(t)} + b_2) \in \mathbb{R}^{|V|}$$

hidden states

$$h^{(t)} = \sigma(W_h h^{(t-1)} + W_e e^{(t)} + b_1)$$


$h^{(0)}$ is the initial hidden state

word embeddings

$$e^{(t)} = E x^{(t)}$$

words / one-hot vectors

$$x^{(t)} \in \mathbb{R}^{|V|}$$




Note: this input sequence could be much longer now!

2. Tóm tắt văn bản bằng trích xuất

2.3. Kiến trúc mô hình

- CNN trong NLP:



2. Tóm tắt văn bản bằng trích xuất

2.4. Kiến trúc mô hình

- **CNN – RNN:**

- **CNN:** làm việc ở word-level, để trích xuất các đặc trưng cục bộ từ từng câu (n-grams) => vector đại diện cho mỗi câu.
- **RNN:** vector được đưa vào RNN (GRU) để nắm bắt ngữ cảnh giữa các câu trong tài liệu (câu trước và sau liên quan gì tới nhau).

=> mô hình học được các mẫu n-gram quan trọng (nhờ CNN), hiểu được ngữ cảnh toàn tài liệu (nhờ RNN) nhưng có thể mất ngữ cảnh dài

- **RNN – RNN:**

- **RNN (1):** mã hóa từ trong câu => ra biểu diễn từng câu.
- **RNN (2):** mã hóa chuỗi các câu trong văn bản => ra biểu diễn tài liệu.

=> mô hình học sâu cấu trúc tuần tự, cả trong câu (word order) và giữa các câu nhưng chậm hơn

2. Tóm tắt văn bản bằng trích xuất

2.4. Đánh giá

- Tiêu chí đánh giá ROUGE: đo độ giống nhau giữa bản tóm tắt mô hình tạo ra và bản tóm tắt do con người viết dựa trên so sánh các chuỗi từ (n-grams)
 - ROUGE-1: Đo trùng unigram (từng từ riêng lẻ)
 - ROUGE-2: Đo trùng bigram
 - ROUGE-L: Đo độ dài chuỗi con chung dài nhất (Longest Common Subsequence - LCS)

