

BÀI THỰC HÀNH SỐ 3



Content

1. Giới thiệu Bài toán Truy xuất thông tin
2. Lab 01 – Truy xuất thông tin văn bản pháp luật
3. Lab 03 – Tự động hoàn thiện tiêu đề trên StackOverflow.

1. Bài toán Truy xuất thông tin

1.1 Tổng quan

- Mục tiêu: Cho một truy vấn (query), tìm ra văn bản (document) phù hợp nhất trong một tập dữ liệu lớn.
- Ứng dụng:
 - Tìm kiếm văn bản
 - Hỏi đáp (Q&A)
 - Hệ thống gợi ý.

1. Bài toán Truy xuất thông tin

1.1 Bi-Encoder

- Ý tưởng chính:
 - Encode tập documents thành vector embedding.
 - Encode truy vấn (query).
 - Tính toán độ tương đồng (thường dùng cosine similarity) giữa query và các document đưa ra các document có độ tương đồng cao nhất.

```
Embedding_Q = Encoder(query)
Embedding_D = Encoder(document)
Score = similarity(Embedding_Q, Embedding_D)
```

1. Bài toán Truy xuất thông tin

1.2 Cross-Encoder

- Ý tưởng chính:
 - Nối câu truy vấn (query) và từng document lại.
 - Tính toán độ liên quan (relevance score) và xếp hạng (re-rank) giảm dần.

```
Input = [CLS] query [SEP] document  
Score = Encoder(Input)[CLS]
```

1. Bài toán Truy xuất thông tin

1.3 So sánh 2 kiến trúc

Đặc điểm	Bi-Encoder	Cross-Encoder
Tốc độ	Nhanh ($m + n$)	Chậm ($n * m$)
Độ chính xác	Thấp hơn, không tối ưu cho ngữ cảnh tương tác sâu giữa query và document.	Cao, mô hình có thể học các tương tác phức tạp giữa query và document
Hiệu quả ở quy mô lớn (khi dùng độc lập)	Hiệu quả hơn	Kém hiệu quả hơn

1. Bài toán Truy xuất thông tin

1.4 Chiến lược phổ biến

- Tận dụng cả tốc độ của Bi-Encoder và độ chính xác của Cross-Encoder
- Quy trình:
 - Bi-Encoder để lọc ra top-K documents nhanh.
 - Cross-Encoder để rerank top-K đó dựa trên độ chính xác cao hơn.

2. Bài toán Truy xuất thông tin văn bản pháp luật

2.1 Sử dụng pretrained model

- Model sử dụng:
 - Bi-Encoder:
 - Cross-Encoder

- Dataset:

	Tập documents	Tập queries
Kích thước	3263	
Features	law_id, article_id , title, text	question_id, question, relevant_articles (law_id + article_id)

- Chiến lược (đã giới thiệu ở trên)
- Metrics: Accuracy (số dự đoán đúng / tổng số dự đoán)

2. Bài toán Truy xuất thông tin văn bản pháp luật

2.2 Fine-tune Bi-Encoder

- Dataset

	question	answer	label
0	Mức phạt khi dừng, đỗ xe ô tô trên đường cao t...	Ban hành kèm theo Thông tư liên tịch này các m...	0
1	Máy móc như thế nào được hiểu là máy móc đã qu...	1. Các loại thuế, khoản thu khác thuộc ngân sá...	0
2	Phiếu đồng ý tham gia nghiên cứu y sinh học li...	Trong Thông tư này, các từ ngữ dưới đây được h...	1
3	Xây dựng trang trại nuôi lợn quy mô nhỏ cách c...	Chủ trì, phối hợp với Bộ Tài chính, Bộ Giao th...	0
4	Mức chi quản lý chương trình đề án khuyến công...	1. Chi hỗ trợ thành lập doanh nghiệp sản xuất ...	1

- Tiền xử lý:
 - Loại bỏ null
 - Cân bằng dữ liệu
- LossFunction: MultipleNegativesRankingLoss

3. Tự động hoàn thiện tiêu đề trên StackOverflow

3.1 Bài toán

- Các nghiên cứu trước đây tập trung vào việc tạo tiêu đề từ đầu dựa trên nội dung bài viết
- Nghiên cứu này đề xuất một hướng tiếp cận mới: hoàn thiện tiêu đề dựa trên phần tiêu đề chưa đầy đủ mà người dùng đã nhập, kết hợp với nội dung mô tả và đoạn mã trong bài viết.

